

BDA - Practicas ETL Pentaho

Alberto Piedra

November 2025

Contents

1	Análisis y diseño del Warehouse	2
1.1	Identificación de los procesos de negocio	2
1.2	Definición del nivel de detalle o granularidad	2
1.3	Identificación de las dimensiones	2
1.4	Identificación de los hechos	2
2	ETL Modelo Estrella	4
2.1	RAW	4
2.2	SILVER	6
2.3	GOLD	10
2.4	Analisis con Athena	16

1 Análisis y diseño del Warehouse

1.1 Identificación de los procesos de negocio

En este almacén de datos los procesos claves serán:

- Análisis de géneros: Analizar los géneros más intercambiados
- Análisis de las editoriales: Analizar las editoriales que contienen más libros en el top.

1.2 Definición del nivel de detalle o granularidad

La granularidad de nuestro almacén será de tipo transaccional ya que cada fila de la tabla de hechos representa un libro distinto.

1.3 Identificación de las dimensiones

Este almacén de datos cuenta con seis tablas de dimensiones, que son:

- Dimensión de datos del libro: Incluye información detalles acerca del libro: Su título, el idioma en el que esta escrito, una descripción del mismo, tags, el código ISBN, los premios que haya recibido y la categoría de edad del libro.
- Dimensión de autor: Incluye el nombre del autor del libro.
- Dimensión de editorial: Incluye el nombre de la editorial a la que pertenece el libro.
- Dimensión de genero: Incluye el genero al que pertenece el libro.
- Dimensión de localización: Incluye el pais en el que el libro es más popular.

1.4 Identificación de los hechos

En este almacén de datos tenemos una tabla de hechos que contiene los siguientes datos:

- book-key: Es la clave principal cada una representa un libro distinto y tambien sirve como clave foranea para conectar la tabla de hechos con la dimensión de Datos-libro.
- Autor-ID: Es la clave foránea que conecta la tabla de hechos con la dimensión de autor.
- Genero-ID: Es la clave foránea que conecta la tabla de hechos con la dimensión de genero.
- Editorial-ID: Es la clave foránea que conecta la tabla de hechos con la dimensión de editorial

- Localización-ID: Es la clave foránea que conecta la tabla de hechos con la dimensión de localización
- rating-average: Es el promedio de puntuación que le han puesto los usuarios a un libro.
- page-count: Es el total de páginas que tiene un libro.
- bestseller: Se trata de una dimensión degenerada que nos dice si un libro ha sido catalogado como best-seller
- adaptado-película: Se trata de una dimensión degenerada que nos dice si un libro ha sido adaptado a película.
- publicationYear: Es el año en el que se publico un libro.

2 ETL Modelo Estrella

Realizaremos un ETL siguiendo el esquema RAW-SILVER-GOLD con un modelo en estrella utilizando las herramientas que nos proporciona AWS, utilizaremos:

- S3: Es la herramienta de almacenamiento que utilizaremos, aquí guardaremos los datos que utilizaremos en crudo (RAW) , los datos después de las transformaciones (SILVER) y los datos separados en la tabla de hechos y sus distintas dimensiones (GOLD)
- Glue: Es un servicio que utilizaremos para realizar las transformaciones y mover los datos desde un bucket de S3 hasta otro.
- Athena: Es una herramienta que utilizaremos para realizar consultas a nuestro almacén de datos y comprobar que el ETL se ha realizado correctamente.

2.1 RAW

Para nuestro ETL utilizaremos un dataset de los libros más populares para intercambiar. Así quedaría nuestro modelo en estrella con la tabla de hechos y sus dimensiones.




Figure 1: Este sera el modelo que utilizaremos para nuestro ETL

Lo primero que tendremos que hacer es que en la herramienta de S3 creemos un bucket donde realizaremos nuestro ETL y crearemos 3 carpetas distintas (RAW, SILVER, GOLD).




Figure 2:




Figure 3:

Dentro de la carpeta de RAW añadiremos el CSV con nuestros datos de origen que utilizaremos para nuestro ETL




Figure 4:




Figure 5: Comprobamos que se ha cargado el CSV

Con nuestro dataset cargado, ya podremos avanzar hacia la parte de la transformación (SILVER)

2.2 SILVER

En esta parte del esquema, realizaremos las transformaciones que necesitemos para mejorar la calidad del dataset antes de crear las dimensiones y la tabla de hechos.

Utilizaremos la herramienta de AWS Glue para realizar un trabajo y mejorar el dataset.




Figure 6: Trabajo para mejorar la calidad del dataset

El trabajo que crearemos sacará los datos del bucket RAW que hemos creado con anterioridad.

Los datos serán transformados mediante esta consulta SQL que se encargará de quitar los espacios en blanco de algunos valores, cambiar el tipo de alguno de ellos para convertirlos en numéricos, cambiar los valores a minúsculas para evitar duplicados que estén escritos de formas distintas.

```

1  SELECT
2      id AS book_id,
3      TRIM(title) AS title,
4      LOWER(TRIM(author)) AS author_name,
5      LOWER(TRIM(genre)) AS genre_name,
6      LOWER(TRIM(language)) AS language,
7      TRIM(publisher) AS publisher_name,
8      LOWER(TRIM(age_category)) AS age_category,
9      TRIM(description) AS description,
10     CAST(publicationYear AS INTEGER) AS publication_year,
11     CAST(pageCount AS INTEGER) AS page_count,
12     CAST(rating_average AS DOUBLE) AS rating_average,
13
14     COALESCE(awards, 'None') AS awards,
15     CASE
16         WHEN movie_release_year IS NULL OR movie_release_year = 0 THEN
17             ELSE CAST(movie_release_year AS INTEGER)
18     END AS movie_release_year,
19
20     CAST(bestseller_status AS BOOLEAN) AS is_bestseller,
21     CAST(adapted_to_movie AS BOOLEAN) AS is_movie_adapted,
22
23     TRIM(isbn) AS isbn,
24     TRIM(most_popular_country) AS country_code
25
26 from myDataSource
27 WHERE id IS NOT NULL
28     AND rating_average BETWEEN 0 AND 5
29     AND pageCount > 0
30     AND title != ''

```

Figure 7: Consulta transformaciones

Tras estas transformaciones, guardaremos los datos transformados en la carpeta SILVER dentro de nuestro bucket en formato parquet.

Data target properties - S3

Name

Amazon S3

Node parents

Choose which nodes will provide inputs for this one.

Choose one or more parent node

SQL Query
SqlCode - Transform

Format

Parquet

Compression Type

Snappy

S3 Target Location

Choose an S3 location in the format s3://bucket/prefix/object/ with a trailing slash (/).

s3://aws-etl-sbd/Silver/

View

Browse S3

Data Catalog update options | Info

Choose how you want to update the Data Catalog table's schema and partitions. These options will only apply if the Data Catalog table is an S3 backed source.

☒ Do not update the Data Catalog

☐ Create a table in the Data Catalog and on subsequent runs, update the schema and add new partitions

☐ Create a table in the Data Catalog and on subsequent runs, keep existing schema and add new partitions


File partitioning | Info

Choose if you want the output to be saved into autogenerated or in a predesignated number of partitions.

☒ Autogenerate files (Recommended)

Figure 8:

Comprobamos que los datos se hayan transformado correctamente



Enter your SQL query here
Example: SELECT * FROM data LIMIT 4

EXECUTE **RELOAD QUERY**

← PREVIOUS **→ NEXT**

Showing row #1 to #100 of 990 total


book_id - str	title - str	author_name - str	genre_name - str	language - str	publisher_name - str	age_category - str
1	Harry Potter and the Sorcerer's Stone	j.k. rowling	fantasy	english	Bloomsbury	children
2	To Kill a Mockingbird	harper lee	southern gothic	english	J.B. Lippincott & Co.	adult
3	1984	george orwell	dystopian	english	Secker & Warburg	adult
4	The Great Gatsby	f. scott fitzgerald	tragedy	english	Charles Scribner's Sons	adult
5	The Hobbit	j.r.r. tolkien	fantasy	english	George Allen & Unwin	children
6	Pride and Prejudice	jane austen	romance	english	T. Egerton	adult
7	The Catcher in the Rye	j.d. salinger	realism	english	Little, Brown and Company	young adult
8	The Da Vinci Code	dan brown	thriller	english	Doubleday	adult
9	The Hunger Games	suzanne collins	dystopian	english	Scholastic	young adult
10	The Lord of the Rings	j.r.r. tolkien	fantasy	english	George Allen & Unwin	adult

Figure 9:

Con las transformaciones ya realizadas, podremos seguir con la última parte, la creación de la tabla de hechos y las distintas dimensiones (GOLD).

2.3 GOLD

Lo primero que haremos será crear una carpeta para cada dimensión y para la tabla de hechos dentro de la carpeta GOLD en nuestro bucket.



Objects (7)
Objects are the fundamental entities stored in Amazon S3. You can use [Amazon S3 inventory](#) to get a list of all of your objects in your bucket. For others to access your objects, you'll need to explicitly grant them permissions. [Learn more](#)

Find objects by prefix

Name	Type	Last modified	Size	Storage class
Consultas/	Folder	-	-	-
DIM_Autor/	Folder	-	-	-
DIM_datosLibros/	Folder	-	-	-
DIM_Editorial/	Folder	-	-	-
DIM_Genero/	Folder	-	-	-
DIM_Localización/	Folder	-	-	-
FACT_Libros/	Folder	-	-	-

Figure 10:

Luego, crearemos el trabajo que se encargará de crear las distintas tablas de dimensiones, poblarlas y crear la tabla de hechos.




Figure 11: Trabajo para crear dimensiones y tabla de hechos

En este trabajo tendremos un bucket de Origen que sera el bucket de SILVER donde guardamos nuestros datos tras las transformaciones, que sera accedido por diferentes consultas que serán las encargadas de crear las distintas dimensiones y la tabla de hechos.

Cada consulta para crear una dimensión será similiar a estas:

```
SQL query  
Enter a SQL statement to add to your job.  
  
1 SELECT  
2     row_number() OVER () as author_id,  
3     author_name  
4 FROM (SELECT DISTINCT author_name FROM myDataSource)
```

Figure 12: Creación de la dimensión de autor

```
1 SELECT  
2     row_number() OVER (ORDER BY title) as book_key,  
3     title,  
4     isbn,  
5     publication_year,  
6     language,  
7     age_category,  
8     description  
9 FROM (  
10    SELECT DISTINCT  
11        title,  
12        isbn,  
13        publication_year,  
14        language,  
15        age_category,  
16        description  
17    FROM myDataSource  
18 )
```

Figure 13: Creación de la dimensión de datosLibros

Todas las consultas se guardarán en su respectiva carpeta dentro del bucket para poder acceder a algún dato en específico sin tener que hacer consultas con join que tardarían más y consumirían más.

Name

DatosLibro

Node parents

Choose which nodes will provide inputs for this one.

Choose one or more parent node

dim_datosLibro X
SqlCode - Transform

Format

Parquet

Compression Type

Snappy

S3 Target Location

Choose an S3 location in the format s3://bucket/prefix/object/ with a trailing slash (/).

s3://aws-etl-sbd/Gold/DIM_DatosLibro, X View Browse S3

Data Catalog update options | Info

Choose how you want to update the Data Catalog table's schema and partitions. These options will only apply if the Data Catalog table is an S3 backed source.

☒ Do not update the Data Catalog

☐ Create a table in the Data Catalog and on subsequent runs, update the schema and add new partitions

☐ Create a table in the Data Catalog and on subsequent runs, keep existing schema and add new partitions

File partitioning | Info

Choose if you want the output to be saved into autogenerated or in a predesignated number of partitions.

☒ Autogenerate files (Recommended)

Figure 14: Guardamos la dimensión dentro del bucket

Crearemos la consulta para nuestra tabla de hechos, haremos que pueda acceder a la tabla de origen y a las demás tablas de dimensiones.

Transform

Name

TablaHechos

Node parents

Choose which nodes will provide inputs for this one.

Choose one or more parent node

dim_datosLibro
SqlCode - Transform

Amazon S3
S3 - DataSource

dim_localizacion
SqlCode - Transform

dim_editorial
SqlCode - Transform

dim_autor
SqlCode - Transform

dim_genero
SqlCode - Transform

Associate an alias with each input source

Info

Edit the aliases used for the inputs to this node.

Input sources

SQL aliases

dim_datosLibro

Amazon S3

dim_localizacion

dim_editorial

dim_autor

dim_genero

dim_datosLibro

myDataSource

dim_localizacion

dim_editorial

dim_autor

dim_genero

Figure 15: Conexión tabla de hechos con las dimensiones

SQL query

Enter a SQL statement to add to your job.

```
1  SELECT
2      b.book_key,
3      a.author_id,
4      g.genre_id,
5      l.country_id,
6      e.publisher_id,
7      s.rating_average,
8      s.page_count,
9      s.is_bestseller,
10     s.is_movie_adapted,
11     s.publication_year
12 FROM myDataSource s
13 JOIN dim_datosLibro b ON s.title = b.title AND s.isbn = b.isbn
14 JOIN dim_autor a ON s.author_name = a.author_name
15 JOIN dim_genero g ON s.genre_name = g.genre_name
16 JOIN dim_localizacion l ON s.country_code = l.country_code
17 JOIN dim_editorial e ON s.publisher_name = e.publisher_name
```

Figure 16: Utilizaremos esta consulta para crear nuestra tabla de hechos

Guardaremos el resultado de este trabajo en la carpeta que hemos creado anteriormente en nuestro bucket.

Data target properties - S3

Name

Amazon S3

Node parents

Choose which nodes will provide inputs for this one.

Choose one or more parent node

TablaHechos

SqlCode - Transform

Format

Parquet

Compression Type

Snappy

S3 Target Location

Choose an S3 location in the format s3://bucket/prefix/object/ with a trailing slash (/).

Q

s3://aws-etl-sbd/Gold/FACT_Libros/

X

View

Browse S3

Figure 17:

Lo último que nos quedaría para terminar nuestro ETL seria añadir un Crawler que acceda a estos datos y los guarde en una base de datos para poder acceder a ellos mediante Athena.

Review and create

Step 1: Set crawler properties

Set crawler properties

Name	Description	Tags
Crawler-Carga-Gold	Crawler Carga Gold	-

Step 2: Choose data sources and classifiers

Data sources (1)

The list of data sources to be scanned by the crawler.

Type	Data source	Parameters
S3	s3://aws-etl-sbd/Gold/	Recrawl all

Step 3: Configure security settings

Configure security settings

IAM role	Security configuration	Lake Formation configuration
LabRole	-	-


Step 4: Set output and scheduling

Set output and scheduling

Database	Table prefix - optional	Maximum table threshold - optional	Schedule
db_books_gold	-	-	On demand

Figure 18:

Comprobaremos que el crawler funcione y se creen las distintas tablas en nuestro almacén de datos.



The screenshot shows the AWS Glue console interface for a database named 'db_books_gold'. It displays the database properties and a list of tables. The tables listed are: dim_autor, dim_datoslibro, dim_editorial, dim_genero, dim_localizaci_n, and fact_libros. Each table entry includes its name, database, location, classification, deprecated status, and links to view data, data quality, and column statistics.

Name	Database	Location	Classification	Deprecated	View data	Data quality	Column statistics
dim_autor	db_books_gold	s3://aws-eti-dbd/Gold/DM_A	Parquet	-	Table data	View data quality	View statistics
dim_datoslibro	db_books_gold	s3://aws-eti-dbd/Gold/DM_D	Parquet	-	Table data	View data quality	View statistics
dim_editorial	db_books_gold	s3://aws-eti-dbd/Gold/DM_E	Parquet	-	Table data	View data quality	View statistics
dim_genero	db_books_gold	s3://aws-eti-dbd/Gold/DM_G	Parquet	-	Table data	View data quality	View statistics
dim_localizaci_n	db_books_gold	s3://aws-eti-dbd/Gold/DM_L	Parquet	-	Table data	View data quality	View statistics
fact_libros	db_books_gold	s3://aws-eti-dbd/Gold/FACT_I	Parquet	-	Table data	View data quality	View statistics


Figure 19:

Ya podremos utilizar la herramienta de Athena para realizar consultas a nuestras tablas.

2.4 Analisis con Athena

Utilizando Athena realizaremos dos consultas a nuestros datos:

- La primera consulta será para analizar que genero de libro es el que tiene mejor clasificación promedio según los usuarios.



The screenshot shows the AWS Athena console with a SQL query executed. The query selects genre name, total books, rating average, average pages, and best-selling count, ordered by rating average. The results are displayed in a table with 5 columns: Genero, Total_Libros, Rating_Promedio, Promedio_Paginas, and Cantidad_BestSellers. The results show three genres: fable, graphic novel, and poetry.

```

1 SELECT
2   g.genre_name AS Genero,
3   COUNT(f.book_key) AS Total_Libros,
4   ROUND(AVG(f.rating_average), 2) AS Rating_Promedio,
5   ROUND(AVG(f.page_count), 0) AS Promedio_Paginas,
6   SUM(CASE WHEN f.is_bestseller = TRUE THEN 1 ELSE 0 END) AS Cantidad_BestSellers
7 FROM "fact_libros" f
8 JOIN "dim_genero" g ON f.genre_id = g.genre_id
9 GROUP BY g.genre_name
10 ORDER BY Rating_Promedio DESC;

```

#	Genero	Total_Libros	Rating_Promedio	Promedio_Paginas	Cantidad_BestSellers
1	fable	1	4.95	96.0	1
2	graphic novel	6	4.39	273.0	6
3	poetry	3	4.32	220.0	3

Figure 20: Consulta mejor clasificación promedio por genero

- La segunda consulta será para analizar que editoriales tienen la mayor cantidad de libros dentro del top de más intercambiados.

Query 1 : XQuery 2 : X

1 SELECT

2 e.publisher_name AS Editorial,

3 COUNT(f.book_key) AS Total_Libros

4 FROM "fact_libros" f

5 JOIN "dim_editorial" e ON f.publisher_id = e.publisher_id

6 GROUP BY e.publisher_name

7 ORDER BY total_libros DESC

8 LIMIT 10;

SQL Ln 8, Col 10

Run again

Explain i

Cancel

Clear

Create

Reuse query results
up to 60 minutes ago

Query results

Query status

Completed

Time in queue: 105 ms

Run time: 885 ms

Data scanned: 18.05 KB

Results (10)

Copy

Download results CSV

Search rows

< 1 >

#	Editorial	Total_Libros
1	Doubleday	48
2	Knopf	46
3	Simon & Schuster	35
4	Viking	35
5	Little, Brown	30

Figure 21: Consulta editorial con mayor cantidad de libros en el top

17